# Eggs-zoly

## Soup Kernel Challenge

**1,26× быстрее**
**66,94% меньше пиковой памяти**

Две независимые сессии Kaggle T4
Decentrathon 6.0

# Операции с большим словарём

Фиксированный запуск Qwen2.5-1.5B-Instruct на бесплатной T4

## Полная матрица логитов занимает много памяти

Cross-entropy, энтропия, точность и rewind читают одни и те же значения.

## Решение вычисляет логиты блоками

Сохраняем небольшие статистики по токенам и повторно используем их для обязательных выходов Soup.

# Вычисление loss и статистик блоками

## Прямой проход

Проекция блоков до 128 токенов. Triton считает устойчивые max и log-sum-exp, энтропию, argmax и token loss.

## Обратный проход

Пересчитываем блок логитов и его градиент. AMP scale применяется до округления градиента в fp16.

Общий знаменатель и causal shift сохраняются. Внешние вызовы модели возвращают обычные dense logits.

# Результаты полного запуска

Исходники одинаковы в обеих сессиях, в каждой по два повтора каждой стороны

| Показатель | Сессия 1: база / решение | Сессия 2: база / решение |
|---|---|---|
| Время soup train, с | 83,12 / 65,66 | 86,56 / 68,61 |
| Ускорение | 1,2659× | 1,2616× |
| Пик GPU, MiB | 14345 / 4743 | 14345 / 4743 |
| Eval loss | 2,04967 / 2,04966 | 2,04964 / 2,04967 |

Харнесс: медиана времени и максимальный пик памяти. Компиляция входит в время. Публичная eval-выборка.

# Проверки и собственные кернелы

**321 + 79**

тест решения и регрессии Soup
в каждой сессии, без пропусков

## 10 из 10 официальных проверок в каждой сессии

Минимальная собственная доля: 13,5985% и 13,9289%.
Предоставленный пример SwiGLU исключён из этой доли.

# Воспроизведение на T4

### Одна функция solution.apply()

Чистый официальный starter c7c2fcd. Переносим только solution/ с проверенным хешем.

### Полный протокол из notebook

База, решение, решение, база. Все CUDA-тесты без skips и все 10 проверок обязательны.

### python scripts/verify_release.py

Локальный аудит проверяет сохранённые доказательства. Новый GPU-замер выполняется только в Kaggle.

# Ограничения и дальнейшие шаги

## Поддерживаем проверенный контракт

Первый порядок autograd, закреплённые версии и Qwen2/NF4.
Неподдерживаемые вызовы используют исходный путь.

## Отбор по пользе полного запуска

Residual + RMSNorm и LoRA scale/add исключены. Dynamic trimming меняет dropout-градиенты и отклонён.

Публичный notebook содержит полный протокол проверки. Исходники доступны жюри. Скрытую проверку проводит жюри.